

XÂY DỰNG HỆ THỐNG HỌC TIẾNG ANH TƯƠNG TÁC NGỮ CẢNH ỨNG DỤNG KIẾN TRÚC HYBRID AI

Tác giả: Nguyễn Kim Thành

Mục Lục Tổng Quan

01

Bối Cảnh & Đặt Vấn Đề

Thực trạng học tiếng Anh và cái
bấy của ứng dụng thuần Cloud
AI Wrapper.

02

Kiến Trúc & Đa Bộ Não

Bản chất Hybrid AI, mô hình
phễu định tuyến và 6 bộ não AI
cục bộ.

03

Thuật Toán & Toán Học

DistilBERT INT8, Cổng bất định,
SRS thích ứng và định luật Zipf.

04

Thực Nghiệm & Đối Chuẩn

Thử thách ngắt mạng 100%
Offline, tăng tốc 150x và giải
đáp phản biện.

BỐI CẢNH THỰC TẾ

Nỗi Đau Người Học Tiếng Anh



Học Vẹt & Mau Quên

Học 100 từ sau 1 tuần quên 80 từ do thiếu chu kỳ nhắc nhở khoa học.



Luyện Tập Nhàm Chán

Trắc nghiệm A/B/C/D lặp đi lặp lại khiến người học triệt tiêu động lực.



Thiếu Phản Hồi Tức Thì

Viết câu tự do không biết sai đúng ở đâu để điều chỉnh hành vi kịp thời.

Cái Bấy Của Ứng Dụng “Thuần Cloud AI”

2 – 4 Giây

Độ Trễ Phản Hồi Cao

Mỗi lần chấm câu phải chờ đợi phản hồi từ API đám mây gây gián đoạn mạch học.

Bùng Nổ

Chi Phí Token Đắt Đỏ

Càng đông người dùng chi phí API càng tăng theo cấp số nhân, không khả thi mở rộng.

Tê Liệt

Phụ Thuộc Kết Nối Mạng

Mất Internet hoặc nghẽn mạng API là toàn bộ ứng dụng dừng hoạt động hoàn toàn.

Đặt Vấn Đề & Câu Hỏi Nghiên Cứu

Mâu Thuẫn Kỹ Thuật Cốt Lõi

Làm sao để hệ thống vừa **thông minh, hiểu ngữ cảnh** như LLM, vừa **phản hồi tức thì ($< 20\text{ms}$)** và **hoạt động 100% khi mất mạng**?

Câu Hỏi Nghiên Cứu

Liệu có thể thiết kế kiến trúc **Hybrid AI** để máy tính cục bộ tự giải quyết 80–90% tác vụ thường gặp, chỉ kích hoạt Đám mây khi gặp câu hỏi vượt ngưỡng?

Mục Tiêu Nghiên Cứu Cụ Thể

1

6 Bộ Não AI Cục Bộ

Làm chủ thuật toán chạy trực tiếp trên CPU phổ thông không phụ thuộc bên thứ ba.

2

Cổng Bất Định

Tự động nhận biết câu chắc chắn để chấm điểm tại máy, đẩy câu bất định lên Đám mây.

3

Trò Chơi Hóa Giáo Dục

Tích hợp Đấu trường Gacha, game nhập vai Text-RPG và Bản đồ học thuật CEFR A1-C2.

GIÁ TRỊ ỨNG DỤNG

Ý Nghĩa Thực Tiễn Của Đề Tài

-85%

Tiết Kiệm Chi Phí

Cắt giảm chi phí vận hành API cho các trường học và trung tâm đào tạo quy mô lớn.

100%

Bình Đẳng Tiếp Cận

Học sinh vùng sâu vùng xa mạng chập chờn vẫn học tập và nhận phản hồi chấm bài mượt mà.

Local

Bảo Mật Tuyệt Đối

Dữ liệu viết câu và phản xạ học viên được xử lý trên máy trạm, không bị rò rỉ ra máy chủ ngoại.

Bản Chất Kiến Trúc Hybrid AI

ĐỘNG CƠ ĐIỆN NỘI ĐÔ

Local Edge AI (Trí Tuệ Biên)

Chạy trên CPU: Không đòi hỏi GPU đắt tiền.

Nhiệm vụ: Chấm điểm ngữ pháp, nhận diện ý định, tính chu kỳ quên.

Tốc độ: Phản hồi dưới 20ms.

Chi phí: 0 VNĐ tài nguyên đám mây.

ĐỘNG CƠ XĂNG CAO TỐC

Cloud GenAI (Trí Tuệ Đám Mây)

Mô hình: Google Gemini 2.5 Flash SDK.

Nhiệm vụ: Sáng tạo cốt truyện Text-RPG, nhập vai Master G.

Kích hoạt: Chỉ gọi khi câu quá dài (> 35 từ) hoặc độ bất định cao.

Tối ưu: Nén cửa sổ trượt giảm 65% token.

Tổng Quan Ngăn Xếp Công Nghệ (Tech Stack)



Giao Diện Frontend

HTML5, CSS3 phong cách Bento Grid, Glassmorphism, JavaScript ES6 và Server-Sent Events (SSE).



Hệ Thống Backend

Python Flask chuẩn MVC phân tầng, bộ điều phối phản hồi thời gian thực và quản lý phiên game.



Thư Viện AI Lỗi

PyTorch, Hugging Face Transformers, Scikit-learn, SciPy Optimize và cơ sở từ vựng Wordfreq.



Đám Mây & CSDL

Google Gemini 2.5 Flash SDK kết hợp cơ chế xoay khóa Ring-Buffer và cơ sở dữ liệu quan hệ MySQL 8.0.

Transformer & Chắt Lọc Tri Thức DistilBERT

Cơ Chế Self-Attention

Giúp mô hình nắm bắt sự phụ thuộc ngữ pháp hai chiều giữa các từ cách xa nhau trong câu.

$$\text{Attention} (Q , K , V) = \text{softmax} \frac{QK^T}{\sqrt{d_k}} V$$

Kỹ Thuật Chắt Lọc (Distillation)

Mô hình gốc BERT: 110 triệu tham số (quá nặng để chạy real-time).

DistilBERT nén gọn: Rút xuống 66 triệu tham số (giảm 40% kích thước).

Bảo toàn năng lực: Giữ vững 97% năng lực hiểu ngôn ngữ tự nhiên.

Tốc độ vượt trội: Tăng tốc xử lý 60% so với kiến trúc BERT tiền nhiệm.

Kỹ Thuật Lượng Tử Hóa Động (INT8 Quantization)

DUNG LƯỢNG MÔ HÌNH

255 → 132 MB

Giảm 48.2% dung lượng lưu trữ

TỐC ĐỘ SUY LUẬN CPU

135 → 18.5 ms

Nhanh gấp 7.27 lần trên CPU

ĐỘ CHÍNH XÁC CoLA

82.7% →

82.4%

Độ chính xác suy giảm không đáng kể
(0.3%)

Mạng Nơ-Ron Ý Định (TF-IDF + MLP)

Cấu Trúc Mạng Đa Tầng (MLP)

Trích xuất đặc trưng cụm từ qua TF-IDF và chuyển tiếp qua 2 tầng ẩn:

Input (TF-IDF) → Dense(100, ReLU) → Dense(50, ReLU) → Softmax(4)

Thời gian suy luận trung bình: **1.18 mili-giây** trên CPU.

4 Không Gian Ý Định Mục Tiêu

1. ask_vocab (Hỏi từ)

2. ask_grammar (Hỏi ngữ pháp)

3. story_action (Lệnh RPG)

4. general_chat (Hội thoại)

Đường Cong Lãng Quên & Thuật Toán Smart SRS

Công Thức Giãn Chu Kỳ Thích Ứng

$$\Delta t = \theta_0 + (\Delta t_{\text{prev}} \times \theta_1) \cdot e^{-\theta_2 \cdot \text{incorrect} - 0.1 \cdot \text{latency}}$$

Kết hợp số lần làm sai và số giây ngập ngừng tư duy để dự đoán chính xác thời điểm rơi trí nhớ.

Phản Xạ Thông Minh

-  **Đúng & Nhanh:** Giãn cách chu kỳ 2 - 3 lần.
-  **Áp dụng suy nghĩ:** Hãm tốc độ giãn chu kỳ.
-  **Chọn sai:** Co chu kỳ tức thì, nhắc học lại trong ngày.

Gợi Ý Từ Vựng Theo Chùm Không Gian Cosine

Khoảng Cách Góc Vector Cosine

$$\text{CosineSim} (u , v) = \frac{u \cdot v}{\| u \| \| v \|}$$

Biểu diễn toàn bộ kho từ vựng theo vector đặc trưng dựa trên ngữ nghĩa và chủ đề bài học.

Học Theo Cành Nhánh Gia Đình

Hệ thống tính trọng tâm vốn từ đã thuộc để đề xuất Top 5 từ mới liên đới gần nhất.

Ví dụ: Học viên học từ *Hospital* → Tự động gợi ý tiếp: *Doctor, Prescription, Emergency*.

Phân Cấp Cấp Độ CEFR Bằng Định Luật Zipf

TẦNG 1: BẢNG BĂM

Từ Điển Chuẩn Oxford 5.000

Tra cứu trực tiếp độ phức tạp từ vựng từ mức A1 đến C2 trong thời gian **0.001 mili-giây** với độ phức tạp $O(1)$.

TẦNG 2: DỰ PHÒNG TẦN SUẤT

Định Luật Tần Suất Zipf

$$z(w) = \log_{10}(P(w)) + 9$$

$z \geq 5.5$: A2 | $4.0 \leq z < 5.5$: B2 | $z < 4.0$: C1/C2.
Nhận diện 100% từ mới và tiếng lóng.

Cơ Chế Nén Cửa Sổ Trượt & Xoay Vòng Khóa API



Nén Cửa Sổ Trượt (Sliding Window)

Sau mỗi 3 lượt tương tác RPG, hệ thống tự động gộp lịch sử cũ thành 2 câu tóm tắt cốt lõi, giúp cắt giảm **65% chi phí Token**.



Xoay Vòng Khóa (Ring-Buffer Multi-Key)

Khi gặp mã lỗi nghẽn hạn ngạch HTTP 429 Quota, bộ điều phối tự động trao sang khóa dự phòng trong **0.05 mili-giây** hoàn toàn trong suốt.

Mô Hình Phễu Định Tuyến 3 Cấp Độ (Routing Funnel)

CẤP 1: BỘ LỌC TỨC THÌ

Tra Cứu Nhanh (< 1ms)

Tra bảng băm, lọc từ dừng, kiểm tra độ dài chuỗi và bóc tách thực thể mục tiêu.

CẤP 2: TRÍ TUỆ BIÊN

Mô Hình Cục Bộ (15–20ms)

DistilBERT INT8 chấm điểm ngữ pháp và tính toán xác suất tự tin Softmax.

CẤP 3: CỨU CÁNH ĐÁM MÂY

Cloud LLM Dự Phòng

Chỉ chuyển lên Gemini khi câu dài trên 35 từ hoặc độ tự tin dưới ngưỡng 55%.

Tỷ lệ điều phối thực tế: 83.3% Xử lý trọn vẹn tại máy • 16.7% Chuyển tiếp Đám mây

Sơ Đồ Phân Tầng Hệ Thống (Multi-Brain Topology)

TẦNG 1: CLIENT GIAO DIỆN

Bento UI Grid • Game Text-RPG • Đấu trường Gacha • Bản đồ CEFR • Âm thanh Native TTS

TẦNG 2: CONTROLLER ĐIỀU PHỐI

Routing Funnel • Cổng bất định (Uncertainty Gate) • Sliding Window • Quản lý phiên game

TẦNG 3: 6 BỘ NÃO CỤC BỘ (100% OFFLINE)

GEC DistilBERT • MLP Intent • DFA NER • Smart SRS • Recommender • CEFR Zipf

TẦNG 4: CLOUD & DỮ LIỆU

Google Gemini 2.5 Flash (SSE Streaming) • Xoay vòng Ring-Buffer API • Cơ sở dữ liệu MySQL 8.0

THIẾT KẾ TRẢI NGHIỆM

Giao Diện Người Dùng Theo Phong Cách Bento Grid



Phân Vùng Khoa Học

Bố trí trực quan các khối chức năng: Luyện viết tự do, Rương Gacha, Lộ trình học và Chuỗi ngày ôn tập.



Thẩm Mỹ Hiện Đại


Nền tối bảo vệ mắt (Dark Mode), mờ kính Glassmorphism và tối ưu hóa chuyển động giao diện chuẩn 60fps.



Phát Âm Bản Xứ Native

Tích hợp phát âm từ vựng chuẩn ngữ điệu trực tiếp từ trình duyệt mà không cần tải tài nguyên âm thanh ngoài.

Đấu Trường Từ Vựng Gacha (Gamification)



Vòng lặp Dopamine: Làm bài tập đúng → Nhận Xu vàng (Coins) → Mở rương thẻ bài → Thẻ rơi tự động nạp vào chu kỳ chống quên Smart SRS.

Game Text–RPG: Học Tiếng Anh Qua Cốt Truyện

Đổ Xúc Xắc D20 & Ngữ Pháp

Hành động của nhân vật phụ thuộc vào xúc xắc D20 cộng điểm ngữ pháp câu viết của học viên.

Viết Đúng & Từ Vựng Hay

Kích hoạt đòn đánh Chí Mạng (Critical Hit), tiêu diệt quái vật và mở khóa trang bị đặc biệt.

Sai Ngữ Pháp Nghiêm Trọng

Hành động thất bại hoàn toàn, nhân vật bị quái vật phản đòn và trừ điểm sinh mệnh (HP).

Bản Đồ Lộ Trình CEFR Từ A1 Đến C2

Cấu Trúc Từng Chặng Milestone

Chuẩn hóa 6 bậc: Phân bổ kiến thức từ cơ bản A1 đến thông thạo C2.

Mô-đun học tập: Mỗi chặng gồm 1 cấu trúc ngữ pháp lõi + 5 từ vựng chuyên đề.

Độ khó tăng tiến: Mở rộng từ câu đơn hiện tại đến mệnh đề đảo ngữ phức tạp.

Vượt Ải Sentence Scramble

Thuật toán tự động xáo trộn ngẫu nhiên vị trí các từ trong câu chuẩn.

Học viên bắt buộc phải sắp xếp đúng cú pháp ngữ pháp mới được mở khóa ải tiếp theo.

Thiết Kế Cơ Sở Dữ Liệu Thích Ứng

user_vocabularies

Lưu số lần làm sai, thời gian ngập ngừng (latency), chu kỳ giãn nở và mốc thời gian nhắc lại SRS kế tiếp.

tests

Ghi lại lịch sử từng câu văn, điểm số DistilBERT, thời gian suy luận (ms) và nhãn phân luồng ('local' hay 'cloud').

story_sessions

Quản lý mạch cốt truyện Text-RPG, điểm sinh mệnh HP, trang bị mở khóa và bản tóm tắt nén của sổ trượt.

Sơ Đồ Luồng Dữ Liệu Đầu Cuối (Sequence Flow)

- 1** Học viên nộp câu văn: Frontend chuyển tiếp yêu cầu đến bộ điều phối Backend.
- 2** Tính toán cục bộ (18.5ms): DistilBERT INT8 sinh điểm số và xác suất tự tin Softmax.
- 3** Rẽ nhánh Cổng bất định: Tự tin $\geq 55\%$ trả kết quả ngay (~19ms); Tự tin $< 55\%$ mở luồng SSE gọi Gemini (< 280ms).
- 4** Đồng bộ cơ sở dữ liệu: Cập nhật số liệu kiểm thử và chu kỳ SRS vào MySQL.

GEC DistilBERT: Động Cơ Chấm Điểm Ngữ Pháp

Huấn Luyện Trên Bộ CoLA

Sử dụng tập ngữ liệu chuẩn quốc tế CoLA (GLUE Benchmark) với 8.551 câu tiếng Anh được gán nhãn ngữ pháp chuẩn xác.

$$P(\text{Acceptable}) = \frac{e^{z_1}}{e^{z_0} + e^{z_1}}$$

Đầu Ra Định Lượng

Thang điểm chuẩn: Quy đổi mượt mà từ 0.0 đến 10.0 điểm.

Độ tự tin Softmax: Cung cấp xác suất toán học phục vụ rẽ nhánh.

Thời gian xử lý: 18.5 mili-giây trên CPU không card rời.

Trạng thái: Chạy độc lập 100% không cần Internet.

Toán Học Cổng Bất Định (Uncertainty Gate)

Đo Lường Độ Tự Tin

$$\text{Confidence} = \max (P_{\text{sai}} , P_{\text{đúng}})$$

$$\text{Uncertainty} = 1 - \text{Confidence}$$

Quy Tắc Ra Quyết Định

Confidence ≥ 0.55 : Máy tính tự tin $\rightarrow$ Chấm điểm và sinh nhận xét tại chỗ, không gọi API.

Confidence < 0.55 : Máy phân vân (Câu dị thường OOD) $\rightarrow$ Chuyển tiếp lên Gemini cứu cánh.

MLP: Nhận Diện Ý Định Người Dùng

Đặc Trưng Đầu Vào

Tiếp nhận câu hỏi hội thoại tự do của học viên (ví dụ: “*Ubiquitous* nghĩa là gì?”).

Trích xuất vector đặc trưng từ khóa đơn (Unigram) và cụm từ đôi (Bigram) qua TF-IDF.

Hiệu Năng Vượt Trội

Thời gian suy luận: 1.18 mili-giây trên CPU.

Độ chính xác độc lập: Đạt 100.0% trên tập kiểm thử 50 câu.

Tự tin Softmax: Trung bình đạt 99.85%.

Phân luồng chính xác: Bóc tách câu hỏi bài tập hay mệnh lệnh game.

DFA NER: Nhận Diện Thực Thể Theo Luật



1. Dấu Ngoặc Kép “”

Ưu tiên tuyệt đối: Bóc tách chính xác 100% từ vựng hoặc cấu trúc nằm trong cặp dấu nháy kép.



2. Cụm Khóa Bản Ngữ

Bắt chính xác thực thể đứng ngay sau các cụm chỉ định như: “cấu trúc”, “từ vựng”, “nghĩa của”.



3. Lọc Stopwords

Tự động triệt tiêu các từ phổ thông như *what, is, you* để tóm lấy từ tiếng Anh có độ dài lớn nhất.

Smart SRS: Dự Đoán Điểm Rơi Trí Nhớ

3 Tham Số Sinh Học Cá Nhân Hóa

θ_0 (Khởi điểm cơ sở): Mốc nhắc nhở ôn lại lần đầu (mặc định 12 giờ).

θ_1 (Hệ số giãn nở): Tốc độ nhân rộng chu kỳ trí nhớ dài hạn (hệ số 1.5).

θ_2 (Mức phạt lãng quên): Trọng số co ngắn chu kỳ khi trả lời sai (hệ số 0.8).

Biên Giới Hạn An Toàn

Không bao giờ co chu kỳ ngắn hơn **30 phút** để tránh quá tải người học.

Không giãn chu kỳ vượt quá **180 ngày** nhằm đảm bảo giữ vững kiến thức bền vững.

TỐI ƯU HÓA THAM SỐ

Tự Tiến Hóa SRS Bằng Thuật Toán TRF

Cơ Chế Phản Xạ Vùng Tin Cậy (TRF)

Khi học viên tích lũy đủ 10 bài kiểm tra, hệ thống tự động tối ưu hóa phi tuyến bộ tham số θ riêng biệt.

Phương pháp Trust Region Reflective tự phản xạ bước nhảy khi chạm ranh giới, triệt tiêu lỗi phân kỳ toán học.

SAI SỐ TUYỆT ĐỐI TRUNG BÌNH (MAE)

1.84 Giờ

Dự đoán cực sát điểm rơi quên lãng của người học

Vocab Recommender: Gợi Ý Từ Vựng Liên Tưởng

Tính Toán Trọng Tâm Vốn Từ

Ánh xạ toàn bộ từ vựng đã thuộc lòng thành một vector trọng tâm trung bình trong không gian đặc trưng.

Tìm kiếm các từ mới chưa học có khoảng cách góc gần với trọng tâm này nhất để kích thích liên tưởng tự nhiên.

TỶ LỆ TRÚNG ĐÍCH (HIT RATE@5)

78.6%

Thời gian suy luận cực nhanh: 3.5 mili-giây

CEFR Zipf: Phân Cấp Trình Độ Từ Vựng

Độ Bao Phủ Tuyệt Đối 100%

Kết hợp bảng băm Oxford 5.000 với thang đo tần suất logarit Zipf từ ngữ liệu hàng tỷ từ của Wordfreq.

Đảm bảo hệ thống không bao giờ gặp lỗi thiếu dữ liệu khi gặp từ mới, thuật ngữ lạ hoặc tiếng lóng mạng.

TƯƠNG QUAN SPEARMAN (CAMBRIDGE)

$$\rho = 0.842$$

Thời gian định mức siêu tốc: 0.01 mili-giây

Nhận Xét Sư Phạm Nội Bộ & Tự Khai Phá Bài Tập

Nhận Xét Master G Phân Cấp (Offline)

A1/A2 (Người mới): Giọng điệu ân cần, khích lệ; chỉ sửa lỗi mạo từ và chia động từ.

B1/B2 (Trung cấp): Giọng điệu thách thức; bắt bẻ thì hoàn thành và liên từ nối.

C1/C2 (Cao cấp): Khắt khe chuẩn bản xứ; bắt bẻ từng sắc thái nghĩa và cụm Collocation.

Cỗ Máy Autonomous Miner

Tiến trình chạy ngầm tự động sinh câu hỏi biến thể mới liên tục mà không lo cạn ngân hàng đề.

DistilBERT tự động thẩm định: chỉ câu đạt cú pháp $\geq 90\%$ mới lưu vào kho đề.

TỔNG HỢP CÔNG NGHỆ

Bảng So Sánh Năng Lực 6 Bộ Não AI Cục Bộ

Bộ Não AI	Nhiệm Vụ Chính	Thuật Toán Cốt Lõi	Tốc Độ CPU	Khả Năng Ngoại Tuyến
1. GEC Engine	Chấm điểm ngữ pháp	DistilBERT INT8 Dynamic	18.5 ms	100% Offline
2. Intent Classifier	Phân loại ý định chat	TF-IDF + Mạng Nơ-ron MLP	1.2 ms	100% Offline
3. Smart SRS	Đoán điểm rơi trí nhớ	Hồi quy Ebbinghaus TRF	0.4 ms	100% Offline
4. CEFR Classifier	Đo độ phức tạp từ vựng	Bảng băm Oxford + Zipf Law	0.01ms	100% Offline
5. Recommender	Gợi ý từ nên học tiếp	Không gian Vector Cosine	3.5 ms	100% Offline
6. NER Engine	Bóc tách từ khóa câu hỏi	Máy trạng thái hữu hạn DFA	0.2 ms	100% Offline

Đổi Chuẩn Lượng Tử Hóa (FP32 vs INT8)

Tiêu Chí Đối Chuẩn	Mô Hình Gốc (FP32)	Mô Hình Lượng Tử Hóa (INT8)	Mức Độ Cải Thiện
Kích thước file lưu trữ	255.4 MB	132.3 MB	Tiết kiệm 48.2% đĩa
Chiếm dụng bộ nhớ RAM	412 MB	198 MB	Tiết kiệm 51.9% RAM
Độ trễ suy luận trên CPU	134.6 ms	18.5 ms	Nhanh gấp 7.27 lần
Độ chính xác chuẩn CoLA	82.7%	82.4%	Suy giảm chỉ 0.3% (Không đáng kể)

Hiệu Quả Cổng Bất Định & Tiết Kiệm Tài Nguyên

83.3%

Xử Lý Hoàn Toàn Tại Máy

Độ trễ trung bình siêu tốc: **17.8 ms**

16.7%

Chuyển Tuyến Lên Gemini

Chỉ câu dài trên 35 từ hoặc câu dị thường OOD

-83.3%

Cắt Giảm Băng Thông & API

Bảo vệ hệ thống khỏi quá tải và tắc nghẽn

Kiểm Thử Ý Định MLP & Mô Phỏng Phản Xạ SRS

Ý Định MLP (50 Câu Độc Lập)

Độ chính xác (Accuracy): 50/50 câu đúng tuyệt đối (100.0%).

Softmax Confidence: Đạt 99.85%.

Thời gian xử lý: 1.18 mili-giây.

Mô Phỏng Phản Xạ Smart SRS

Học viên A (Đúng nhanh 1.2s): Giãn từ 1 ngày → 2.2 ngày → 5 ngày.

Học viên B (Đúng chậm 4.8s): Giãn chậm: 1 ngày → 1.5 ngày → 2.5 ngày.

Học viên C (Sai 1 lần): Co chu kỳ về 13.5 giờ (học lại trong ngày).

Học viên D (Sai 3 lần): Phạt nặng co về 1.2 giờ (ôn tập tức thì).

Thử Thách Rút Dây Mạng (100% Offline Test)

Kịch Bản Cắt Toàn Bộ Internet

Ngắt hoàn toàn Wi-Fi và dây mạng LAN của máy chủ thử nghiệm, tiến hành 15 thao tác học tập liên hoàn:

Đăng nhập • Quay Gacha • Vượt ải xáo từ • Nộp bài viết tự do • Xem điểm DistilBERT • Xem nhận xét Master G • Kiểm tra chu kỳ SRS.

15 / 15

Thành Công 100%

Hoàn toàn không phát sinh bất kỳ thông báo lỗi kết nối mạng nào

Đối Chuẩn Độ Trễ: Nhanh Gấp 150 Lần

Tác Vụ Kiểm Thử	Ứng Dụng Thuần Cloud LLM	Nền Tảng Hybrid AI (TAP)	Mức Độ Tăng Tốc
Chấm điểm ngữ pháp câu	2.100 - 3.800 ms	18.5 ms	Nhanh gấp ~150 lần
Phân loại ý định câu chat	1.200 - 1.800 ms	1.2 ms	Nhanh gấp ~1.200 lần
Xác định cấp độ từ vựng	800 - 1.500 ms	0.01 ms	Gần như tức thời
Tính toán lịch ôn chống quên	Không hỗ trợ nội suy	0.4 ms	Tức thời tại máy

HIỆU QUẢ KINH TẾ

Tiết Kiệm Chi Phí & Tối Ưu Tài Nguyên

-87.5%

Cắt Giảm Token Đám Mây

Nhờ xử lý tại chỗ và nén lịch sử cửa sổ trượt

< \$35

Chi Phí Cho 10.000 User/Tháng

So với mức \$500 - \$700 của giải pháp thuần Cloud

< 450 MB

Mức Tiêu Thụ RAM

Toàn bộ hệ thống vận hành êm ái trên máy tính phổ thông

ĐỘ TIN CẬY ĐỊNH LƯỢNG

Độ Chính Xác Khoa Học Của Từng Bộ Não

82.38%

GEC DistilBERT

F1-Score đạt 0.811 trên tập chuẩn quốc tế CoLA

0.988

Macro F1 Intent

Nhận diện chuẩn xác 4 phân vùng ý định

1.84h

MAE Smart SRS

Sai số giờ nhắc ôn tập bám sát thực tế

0.842

Spearman ρ Zipf

Tương quan cao với từ điển Cambridge EVP

ĐÁNH GIÁ NGƯỜI DÙNG

Khảo Sát Thực Tế (Thử Nghiệm 30 Học Viên Trong 4 Tuần)

73.3%

Tỷ Lệ Giữ Chân Day-7

Vượt xa mức 25 - 30% của các ứng dụng EdTech thông thường

18.5 Phút

Thời Lượng Học Hàng Ngày

Nhờ sức hút tương tác của Text-RPG và vòng lặp Gacha

86.4 / 100

Điểm Thỏa Mãn SUS Score

Xếp hạng A - Mức độ trải nghiệm sản phẩm xuất sắc

Giải Quyết Bài Toán “Tam Giác Vàng” Kỹ Thuật AI



1. Tốc Độ Siêu Việt

Phản hồi dưới 20ms trực tiếp trên CPU, xóa bỏ hoàn toàn thời gian chờ đợi phản hồi.



2. Chi Phí Tiệm Cận 0đ

Không tốn token đám mây cho các bài tập hàng ngày, giảm 85% gánh nặng máy chủ.



3. Ngữ Cảnh Sâu Sắc

Vẫn giữ được khả năng sáng tạo cốt truyện và nhập vai phong phú nhờ Cloud LLM.

Tổng Kết Kết Quả Đạt Được

- ✓ Huấn luyện và lượng tử hóa thành công mô hình **DistilBERT INT8** chạy thời gian thực trên CPU.
- ✓ Xây dựng trọn vẹn **6 bộ não AI cục bộ** chạy hoàn toàn ngoại tuyến không phụ thuộc Internet.
- ✓ Thiết kế **Cổng bất định (Uncertainty Gate)** và cơ chế xoay vòng khóa phòng thủ lỗi hạn ngạch 429.
- ✓ Hoàn thiện ứng dụng Full-stack hoàn chỉnh: Bento UI, Đấu trường Gacha, Game RPG, Lộ trình A1-C2.

Nhìn Nhận Hạn Chế & Hướng Phát Triển

⚠ Hạn Chế Hiện Tại

Bản chất GEC: DistilBERT mới dừng ở mức chấm Đúng/Sai, chưa tự sửa câu trực tiếp.

Khởi đầu lạnh SRS: Thuật toán Ebbinghaus cần tối thiểu 10 bài test để tự học tối ưu.

Không gian TF-IDF: Chưa bao quát hết các từ đồng nghĩa sâu nếu lệch từ khóa giải nghĩa.

🗣 Hướng Phát Triển Tiếp Theo

Seq2Seq GEC cục bộ: Nén mô hình Flan-T5-small để vừa chấm vừa tự động viết lại câu đúng.

Chuẩn hóa FSRS: Chuyển đổi mô hình trí nhớ sang chuẩn FSRS với 3 biến trạng thái nhận thức.

Speech AI Biên: Tích hợp Whisper nén cục bộ để chấm điểm phát âm tiếng Anh từ micro.

Câu Hỏi 1: Nhiệm Vụ Giải Quyết Cụ Thể?



1. Chấm Ngữ Pháp < 20ms

Chấm câu tức thì trên thang điểm 10 và tính độ tự tin Softmax tại máy.



2. Smart SRS Cá Nhân Hóa

Đo lường số lần làm sai và độ trễ ngập ngừng để tìm đúng điểm rơi trí nhớ.



3. Đoán Ý Định Trong 1.2ms

Nhận diện 4 nhóm nhu cầu chat tự do mà không phụ thuộc Internet.



4. Cắt Giảm Chi Phí & Offline

Chạy 100% khi ngắt mạng, tiết kiệm 85% chi phí API đám mây.

Câu Hỏi 2: Dữ Liệu & Bản Đồ Tri Thức Sử Dụng

NGỮ LIỆU CHUẨN

Tập CoLA (GLUE Benchmark)

8.551 câu tiếng Anh chuẩn và lỗi sai được gán nhãn chuyên gia dùng để huấn luyện mô hình DistilBERT.

TỪ ĐIỂN HỌC THUẬT

Oxford 5.000 & Wordfreq

Bảng băm 5.000 từ chuẩn Oxford tra cứu $O(1)$ kết hợp kho dữ liệu tần suất hàng tỷ từ đo độ hiếm Zipf.

BẢN ĐỒ GIÁO TRÌNH

Lộ Trình 6 Bậc CEFR

Chuẩn hóa toàn bộ cấu trúc câu từ thì đơn giản đến đảo ngữ điều kiện loại 3 và bài thi Sentence Scramble.

Câu Hỏi 2 (Tiếp): Quy Trình 8 Bước Triển Khai

B1: Huấn luyện DistilBERT trên CoLA bằng PyTorch (FP32).

B2: Lượng tử hóa động INT8 (Nén xuống 132MB, tăng tốc 7.2x).

B3: Huấn luyện pipeline TF-IDF + MLP nhận diện ý định.

B4: Lập trình Smart SRS bằng SciPy Optimize phương pháp TRF.

B5: Xây dựng backend Flask chuẩn MVC và cơ sở dữ liệu MySQL.

B6: Kết nối Gemini, xoay vòng Ring-Buffer Key và luồng SSE.

B7: Xây dựng Bento UI, bàn cờ Text-RPG và vòng lặp Gacha.

B8: Viết kịch bản kiểm thử tự động benchmark đo đặc định lượng.

Câu Hỏi 3: 4 Nhóm Chỉ Số Đánh Giá Định Lượng

1. Chỉ Số ML

Accuracy CoLA: 82.38% • Macro F1
Intent: 0.988 • MAE SRS: 1.84h • Zipf p:
0.842.

2. Kỹ Thuật Hệ Thống

Độ trễ: 18.5ms (nhanh 150x) • Tiết
kiệm 48% ROM • Giảm 52% RAM • Cắt
87.5% Token.

3. Kháng Lỗi & Bền Bỉ

Tỷ lệ lỗi gián đoạn 429: 0.0% • Vận
hành 100% tính năng khi rút hoàn toàn
dây mạng.

4. Sự Phạm & UX

Day-7 Retention: 73.3% • Thời lượng
học: 18.5 phút/ngày • SUS Score:
86.4/100 (Hạng A).

XÂY DỰNG HỆ THỐNG HỌC TIẾNG ANH TƯƠNG TÁC NGỮ CẢNH ỨNG DỤNG KIẾN TRÚC HYBRID AI

Tác giả: Nguyễn Kim Thành